

CMIN-SR 项目实施与概念说明书

这份文档是给项目作者自己看的“总地图”。它不替代论文，也不替代各阶段实验日志，而是回答三个问题：

1. 这个项目到底在研究什么？
2. 代码和实验是如何一步步实现这个想法的？
3. 写论文和复现实验时，应该抓住哪条主线，哪些内容只放附录或失败分析？

本文档对应当前仓库状态。项目根目录为：

```
D:/graduate_first/research/MS
```

论文工作区为：

```
D:/graduate_first/research/MS/paper_writing_workspace
```

1. 一句话总结

CMIN-SR 是一个用于有限样本随机信号的 **validity-aware spectral diagnostic framework**。

它不是一个保证从短时间序列中精确恢复 MRW 参数 λ_2 的估计器，也不是一个证明真实数据服从 MRW 机制的模型。它更合理的定位是：

在有限样本、多尺度统计噪声和高阶矩不稳定条件下，
组织 empirical spectrum、monofractal projection、MRW projection、
residual geometry、curvature、tail instability 等证据，
给出保守的谱几何诊断。

最终论文里最重要的一句话应该是：

```
CMIN-SR should be interpreted as a validity-aware spectral diagnostic framework,  
not as a guaranteed short-window  $\lambda_2$  recovery engine.
```

2. 项目研究的问题

复杂系统、金融波动、湍流、生理信号等时间序列经常表现出多尺度波动和可能的多重分形结构。传统多重分形分析通常会从结构函数或其他多尺度统计量中估计：

- $\zeta(q)$: scaling exponent function;
- $\alpha(q)$: 局部奇异性强度;
- $f(\alpha)$: 多重分形谱;
- H : Hurst / monofractal scaling 坐标;
- λ : MRW 模型中的曲率 / intermittency 坐标。

问题在于，真实研究中样本往往有限，尺度范围有限，高 q 阶矩容易不稳定。于是一个本来是线性的 monofractal 信号，比如 fGn 或 Gaussian，也可能因为 finite-sample noise 看起来有“假曲率”。反过来，一个真正由 MRW 生成的样本，在短窗口里也可能看不出稳定曲率。

所以本项目的核心问题不是简单地问：

这个信号是不是 MRW?

而是问：

在当前样本长度、 q -grid、scale range 和 estimator 下，
经验谱提供了多少支持 monofractal / MRW / boundary / unstable 的证据？
这些证据是否足够稳定，还是只是有限样本伪影？

3. 核心概念

3.1 Empirical spectrum: $\zeta_{\text{emp}}(q)$

$\zeta_{\text{emp}}(q)$ 是从原始时间序列估计出来的经验尺度谱。直观上，它描述不同阶数 q 的波动量如何随尺度变化。

它是整个框架中最脆弱的一环：

```
raw signal x(t)
-> structure functions S_q(a)
-> log-log slope over scales
-> zeta_emp(q)
```

有限样本、尺度选择、高 q 矩不稳定、尾部扰动、regime switching 都会污染 $\text{zeta_emp}(q)$ 。

相关代码：

- `src/mrw_inverse/models/empirical_spectrum.py`
- `src/mrw_inverse/models/robust_zeta_estimator.py`

3.2 Monofractal projection

Monofractal 线性谱写作：

$$\text{zeta_mono}(q) = q^H$$

如果一个经验谱基本是线性的，那么它更适合被 monofractal 解释。项目中会把 $\text{zeta_emp}(q)$ 投影到这个线性族上，得到：

- H_{mono}
- $\text{zeta_mono}(q)$
- $\text{mono_residual_norm}$

直觉：

```
mono_residual_norm 小
=> 线性 monofractal 解释已经足够好
=> 不应该轻易说它是 MRW curved spectrum
```

相关代码：

- `src/mrw_inverse/models/monofractal_projection.py`

3.3 MRW projection

项目采用的 MRW 解析谱族为：

$$\text{zeta_MRW}(q) = q^H - 0.5 * \text{lambda2} * q * (q - 2)$$

其中：

- H 控制整体线性斜率；
- lambda2 控制谱的二次曲率；
- $\text{lambda2} = 0$ 时接近 monofractal 边界；
- lambda2 越大，理论曲率越明显。

项目会把 $\text{zeta_emp}(q)$ 投影到 MRW 二参数族上，得到：

- H_{proj}
- lambda2_proj
- $\text{zeta_mrw}(q)$
- residual_norm

非常重要：

lambda2_proj 是 projection coordinate，不是真实机制证明。

也就是说， $\text{lambda2_proj} > 0$ 只说明“这个经验谱在 MRW 族上的投影坐标有曲率”，不等于真实数据生成机制就是 MRW。

相关代码：

- `src/mrw_inverse/models/mrw_projection.py`

3.4 Residual geometry

项目真正强调的不是单个分数，而是多组证据一起看：

MRW residual	= zeta_emp 与 zeta_mrw 的距离
mono residual	= zeta_emp 与 zeta_mono 的距离
MRW-vs-mono gain	= monofractal residual 被 MRW residual 改善了多少
boundary score	= 是否处于低 lambda2 / mono-MRW 边界
tail instability	= 高 q / heavy-tail 是否不稳定

典型解释：

如果 $\text{MRW residual} < \text{mono residual}$ 且 p_{curved} 高，
才比较支持 MRW-like curved spectrum。

如果 $\text{mono residual} \leq \text{MRW residual}$ 且 p_{mono} 高，
则更像 stable monofractal。

如果 tail instability 高，
则即使有 apparent curvature，也不能轻易解释为 MRW。

相关代码：

- `src/mrw_inverse/models/curvature_diagnostics.py`

3.5 五个诊断分数

项目中常见的分数不是“真实概率”，更准确地说是 calibrated diagnostic scores。

p_scaling

问题：

这个信号是否存在稳定尺度律？

高 p_{scaling} 只说明有稳定 scaling，不说明有 MRW 多重分形曲率。

p_curved

问题：

经验谱是否显著偏离线性 monofractal 谱？

这是 v3 之后引入的重点。它试图把“有没有曲率”从“是不是 MRW”中分离出来。

p_mono

问题：

经验谱是否更适合 `monofractal linear spectrum`?

fGn / Gaussian 的理想表现是：

p_scaling 高
p_curved 低
p_mono 高
p_MRW 低或中低

p_MRW

问题：

经验谱是否稳定、弯曲，并且能被 MRW 二参数族合理解释？

它不能单独解释。必须和 p_curved , p_mono , residuals, tail instability 一起看。

p_boundary

问题：

是否处于 low-lambda2 MRW / monofractal 的边界区域？

low-lambda2 MRW 不是失败，而是边界案例。它理论上就不应该被强行判成 strong MRW。

4. 最终框架流程

最终主线可以画成：

```
raw stochastic signal
-> empirical zeta(q)
-> monofractal projection
-> MRW projection
-> residual / curvature / boundary / instability diagnostics
-> calibrated diagnostic scores
-> finite-sample identifiability interpretation
```

更细一点：

Stage 1: Raw signal to empirical spectrum

```
x(t)
-> structure functions  $S_q(a)$ 
-> zeta_emp(q)
```

Stage 2: Projection geometry

```
zeta_emp(q)
-> zeta_mono(q),  $H_{\text{mono}}$ , mono_residual
-> zeta_MRW(q),  $H_{\text{proj}}$ ,  $\lambda^2_{\text{proj}}$ , MRW residual
```

Stage 3: Diagnostics

```
residuals + curvature + boundary + instability
-> p_scaling, p_curved, p_mono, p_MRW, p_boundary
```

Stage 4: Interpretation

```
conservative evidence organization
not mechanism proof
```

5. 代码结构总览

5.1 核心模型目录

```
src/mrw_inverse/models/
```

主要文件：

- empirical_spectrum.py
 - 基础经验谱估计工具。

- `robust_zeta_estimator.py`
 - deterministic structure-function estimator;
 - 包括 OLS、trimmed、bootstrap、smoothed 等有限样本估计。
- `mrw_projection.py`
 - MRW 二参数投影。
- `monofractal_projection.py`
 - 线性 monofractal 投影。
- `curvature_diagnostics.py`
 - 曲率、线性度、MRW-vs-mono gain、boundary score 等诊断。
- `spectral_geometry_calibrator.py`
 - 小型 spectrum-space calibrator;
 - 输入 zeta / residual / diagnostics;
 - 输出 `p_scaling`, `p_curved`, `p_mono`, `p_MRW`, `p_boundary`。
- `spectral_representation_model.py`
 - CMIN-SR 历史模型主体。
- `zeta_aligned_encoder.py`
 - raw signal 到 `zeta_emp(q)` 的 zeta alignment 模型。

5.2 数据集目录

`src/mrw_inverse/data/`

主要文件:

- `analytic_spectrum_dataset.py`
 - 直接生成解析 `zeta(q)` 曲线;
 - 用于训练 `spectral geometry calibrator`;
 - 不依赖 raw time series。
- `raw_zeta_alignment_dataset.py`
 - 生成 raw time series, 同时提供理论 zeta target;
 - 用于训练 raw zeta alignment。
- `boundary_calibration_dataset.py`
 - same-H fGn/MRW lambda2 sweep;
 - 用于 boundary calibration ablation。

5.3 损失函数目录

`src/mrw_inverse/losses/`

主要文件：

- `spectral_representation_losses.py`
 - 原始 CMIN-SR / v1-v3 相关 loss。
- `spectrum_space_calibration_losses.py`
 - analytic zeta 空间的分类、排序、边界、caution loss。
- `zeta_alignment_losses.py`
 - raw zeta alignment loss。
- `curvature_preserving_zeta_losses.py`
 - band-specific MRW curvature preservation；
 - third-difference smoothness；
 - lambda2 projection consistency；
 - MRW-vs-mono residual margin。

5.4 分析模块

`src/mrw_inverse/analysis/`

主要文件：

- `curvature_identifiability.py`
 - deterministic estimator-level lambda2 recovery study；
 - 比较 OLS / trimmed / bootstrap / smoothed structure-function estimators；
 - 输出 `lambda2_proj` , `residuals`, `curvature scores`, `instability warnings`。

6. 实验阶段如何演化

这个项目不是一步到位，而是通过多轮失败和校正逐渐清楚主线的。下面按阶段解释。

6.1 Proxy / Tiny CMIN / CMIN-Robust

早期阶段主要是在确认：

- 原始网络是否容易把 stable scaling 都误判成 MRW；
- negative controls 是否有用；
- robust / anti-confounding loss 是否能压低明显非 MRW 的假阳性。

这些阶段现在主要作为 legacy / appendix，不建议放主文展开。

相关文档：

- docs/legacy_experiments_map.md
- docs/cmin_robust_training.md
- docs/cmin_robust_multilength.md

6.2 CMIN-SR v1

问题：

模型容易把 fGn 的 stable scaling 也解释成 MRW-compatible。

原因：

p_{MRW} 同时承担了 scaling stability 和 MRW compatibility 两个语义。

结果：

- fGn 的 p_{MRW} 过高；
- 模型会把“稳定尺度律”误读成“MRW-like”。

6.3 CMIN-SR v2: monofractal competition

v2 加入 monofractal projection，让 MRW 和 linear monofractal 竞争。

目标：

如果 `linear monofractal` 已经解释得很好，
就不应该给很高 `p_MRW`。

效果：

- `fGn / Gaussian` 的 `p_MRW` 降低；
- 但 `MRW` 自身的 `p_MRW` 也被压低。

结论：

`v2` 不是失败，但它像是整体压低水位，
还没有真正区分 `linear stable scaling` 和 `curved MRW scaling`。

相关文档：

- `docs/cmin_sr_v2_monofractal_calibration.md`

6.4 CMIN-SR v3: explicit `p_curved`

`v3` 引入 `p_curved`，把问题拆成：

`p_scaling`：是否有稳定尺度律？
`p_curved`：是否有显著曲率？
`p_mono`：是否更适合线性 `monofractal`？
`p_MRW`：是否是稳定、显著弯曲、`MRW-compatible`？

但结果仍是 `partial success`：

- 工程链路跑通；
- `p_curved head` 存在；
- 但 `fGn` 和 `MRW` 的 `p_curved / p_MRW` 仍太接近。

结论：

仅仅加一个 `head` 不够。
问题不只是输出层，而是 `raw zeta_emp` 本身带有有限样本伪曲率。

相关文档：

- docs/cmin_sr_v3_curved_linear_calibration.md

6.5 Boundary Calibration: same-H contrast

这一阶段尝试 same-H fGn/MRW(lambda2 sweep) 对比训练：

同一个 H 下：

fGn(H)

MRW(H, lambda2=0.01)

MRW(H, lambda2=0.03)

MRW(H, lambda2=0.06)

MRW(H, lambda2=0.10)

目标：

让模型学会 `stable scaling` 不等于 `curved MRW`。

结果：

- raw time-series contrastive fine-tuning 仍不足；
- fGn 和 MRW 仍然太像。

结论：

`raw finite-sample spectrum noise` 可能淹没了弱曲率信号。

相关文档：

- docs/cmin_sr_boundary_calibration.md

6.6 Spectrum-Space Calibration

这是关键转折。

做法：

不从 raw time series 学，
而是在干净或可控扰动的 analytic zeta(q) 空间里训练 calibrator。

数据类型包括：

- linear_mono
- boundary_mrw
- curved_mrw
- noisy_mono
- noisy_mrw
- heavy_tail_distorted
- regime_apparent
- ambiguous_mild_curvature

结果很清楚：

- analytic spectrum-space calibrator 能区分 linear / boundary / curved / unstable；
- lambda2 sweep 的 monotonicity 可以达到 1.0；
- heavy-tail / regime 可以被压低 MRW compatibility。

结论：

谱几何解释层是可学的。

瓶颈不是 p_MRW 定义，也不是缺 head。

瓶颈是 raw CMIN-SR 输出的 zeta_emp 太脏。

相关代码：

- src/mrw_inverse/data/analytic_spectrum_dataset.py
- src/mrw_inverse/models/spectral_geometry_calibrator.py
- src/mrw_inverse/losses/spectrum_space_calibration_losses.py

相关文档：

- docs/spectrum_space_calibration.md
- docs/spectral_geometry_calibrator.md

6.7 Raw Zeta Alignment

下一步修 raw signal -> zeta_emp。

目标：

先让 raw encoder 学会输出更干净的 `zeta_emp(q)`，
再交给 spectral geometry calibrator 解释。

结果：

- fGn / Gaussian 的 fake curvature 被明显压低；
- 但是 MRW 的真实曲率也被压掉。

典型结论：

raw zeta alignment 成功把谱变线性，
但太保守，把 MRW 曲率也 over-linearized。

相关代码：

- `src/mrw_inverse/data/raw_zeta_alignment_dataset.py`
- `src/mrw_inverse/models/zeta_aligned_encoder.py`
- `src/mrw_inverse/losses/zeta_alignment_losses.py`

相关文档：

- `docs/raw_zeta_alignment.md`
- `docs/zeta_alignment_comparison.md`

6.8 Curvature-Preserving Zeta Alignment

为修复 over-linearization，引入：

- MRW lambda2 band-specific curvature loss；
- high-lambda MRW 更强二阶曲率匹配；
- third-difference smoothness，而不是二阶差分 flattening；
- lambda2 projection consistency；
- MRW-vs-mono residual margin。

结果：

- fGn fake curvature 能保持被压低；
- 但 MRW medium/high curvature 仍不稳定；
- λ_{2_true} vs λ_{2_proj} correlation 仍接近 0。

结论：

这不是继续加 head 能解决的问题。

可能是当前 q-grid / scale range / T 下 empirical curvature 本身不可可靠识别。

相关代码：

- `src/mrw_inverse/losses/curvature_preserving_zeta_losses.py`

相关文档：

- `docs/curvature_preserving_zeta_alignment.md`
- `docs/curvature_preserving_zeta_comparison.md`

6.9 Finite-Sample Curvature Identifiability Study

最后一个关键阶段：不再训练新模型，而是问：

如果用 deterministic / oracle-like structure-function estimator，
能不能从 raw MRW samples 恢复 λ_{2_true} ？

比较 estimators：

- `structure_ols`
- `structure_trimmed`
- `structure_bootstrap`
- `structure_smoothed`

测试：

- 不同 T；
- 不同 q-grid；
- 不同 scale range；

- analytic zeta -> noisy zeta -> raw zeta bridge;
- analytic / deterministic / neural failure attribution。

核心结果：

在当前短窗口设置下，deterministic estimators 也不能稳定恢复 λ_2 。

这说明 CMIN-SR raw 端失败主要是：

finite-sample empirical spectrum estimation bottleneck

而不是：

网络太小 / head 不够 / loss 不够复杂

相关代码：

- src/mrw_inverse/analysis/curvature_identifiability.py
- experiments/run_finite_sample_curvature_identifiability.py
- experiments/run_scale_length_sensitivity.py
- experiments/run_qgrid_sensitivity.py
- experiments/run_zeta_noise_bridge.py
- experiments/run_cmin_sr_failure_attribution.py

相关文档：

- docs/finite_sample_curvature_identifiability.md
- docs/estimator_curvature_recovery.md
- docs/zeta_noise_bridge.md
- docs/cmin_sr_failure_attribution.md

7. 最终论文主线怎么讲

推荐主线：

1. 多重分形谱估计在有限样本下很难。
2. 单纯从 empirical zeta 曲率判断 MRW 很危险。
3. CMIN-SR 将问题拆成:
 - empirical spectrum estimation
 - + monofractal/MRW projection
 - + spectral geometry calibration
 - + instability warning。
4. 在 clean analytic zeta 空间中, linear/boundary/curved/unstable 谱几何是可区分的。
5. 但在 raw finite samples 中, zeta_emp 质量成为瓶颈。
6. deterministic estimator 也无法稳定恢复 λ_2 , 说明这是有限样本 identifiability limitation。
7. 因此 CMIN-SR 的合理价值是诊断框架, 而不是保证恢复 MRW 参数。

8. 哪些结果放主文, 哪些放附录

8.1 建议主文

1. Spectral geometry calibration
 - 证明解释层在 clean zeta 空间是有效的。
2. Process-family diagnostics
 - 展示 fGn / Gaussian / Student-t / GARCH / RegimeSwitch 不应被简单过度解释成 MRW。
3. Monofractal vs MRW projection
 - 展示 residual geometry 的必要性。
4. Finite-sample curvature identifiability
 - 论文最有价值的负结果 / limitation。
5. Zeta noise bridge / failure attribution
 - 解释为什么 analytic calibrator 接回 raw zeta 会失败。

8.2 建议附录

1. Tiny CMIN / CMIN-Robust 早期版本。
2. CMIN-SR v1/v2/v3 发展过程。
3. Boundary calibration negative result。
4. Raw zeta alignment trade-off。
5. Curvature-preserving zeta alignment trade-off。
6. 完整 estimator-level tables。
7. real-data sanity check。

8.3 不建议主文强讲

- “模型证明某真实数据服从 MRW”。
- “短窗口下能保证恢复 λ_2 ”。
- “CMIN-SR outperform 所有经典多重分形估计器”。
- “p_MRW 是真实机制概率”。

9. 如何复现实验

开发环境中通常使用：

```
conda run -n for_codex python <script.py>
```

或者进入环境：

```
conda activate for_codex  
python <script.py>
```

9.1 快速检查

```
python scripts/smoke_test_paper_pipeline.py
```

9.2 生成论文资产

```
python experiments/paper/generate_all_paper_assets.py --quick
```

9.3 运行主实验 wrapper

```
python experiments/paper/run_exp1_spectral_geometry_calibration.py --quick  
python experiments/paper/run_exp2_process_family_diagnostics.py --quick  
python experiments/paper/run_exp3_boundary_projection.py --quick  
python experiments/paper/run_exp4_finite_sample_identifiability.py --quick  
python experiments/paper/run_exp5_real_world_sanity_check.py --quick
```

9.4 有限样本 identifiability 实验

```
python experiments/run_finite_sample_curvature_identifiability.py --quick
python experiments/run_scale_length_sensitivity.py --quick
python experiments/run_qgrid_sensitivity.py --quick
python experiments/run_zeta_noise_bridge.py --quick
python experiments/run_cmin_sr_failure_attribution.py --quick
```

9.5 论文 LaTeX 编译

进入：

```
paper_writing_workspace/
```

使用 VS Code LaTeX Workshop 或 MiKTeX 编译：

```
pdflatex -> bibtex -> pdflatex -> pdflatex
```

主文件：

```
paper_writing_workspace/main.tex
```

10. 重要输出目录

10.1 模型 checkpoint

```
checkpoints/cmin/
```

重要 checkpoint：

- cmin_sr_synthetic.pt
- cmin_sr_v2_synthetic.pt
- cmin_sr_v3_synthetic.pt
- cmin_sr_calibrated_synthetic.pt
- spectral_geometry_calibrator.pt

- `cmin_sr_zeta_aligned.pt`
- `cmin_sr_zeta_curvature_preserved.pt`

10.2 实验输出

`outputs/reports/`
`outputs/tables/`
`outputs/figures/`

10.3 论文资产

`paper_assets/`
`paper_writing_workspace/paper_assets/`

最近整理过的绘图数据在：

`paper_writing_workspace/paper_assets/figure_data/`

图表审稿报告在：

`paper_writing_workspace/paper_assets/summaries/`

11. 当前论文写作状态

LaTeX 工作区：

`paper_writing_workspace/`

主文件：

`main.tex`

章节：

- `sections/01_introduction.tex`

- sections/02_framework.tex
- sections/03_methods.tex
- sections/04_experiments.tex
- sections/05_results.tex
- sections/06_failure_analysis.tex
- sections/07_discussion.tex
- sections/08_conclusion.tex

辅助文件：

- references.bib
- latex_tables/
- figures/
- paper_assets/
- ARTICLE_STRUCTURE_CN.md
- paper_draft.md
- claim_evidence_table.md
- TODO_missing_evidence.md
- reviewer2_comments.md

12. 图表整理建议

最近审稿整理的结论：

必须重画

- Fig.1 pipeline
 - 当前太像临时流程图；
 - 应改成三阶段 pipeline：
 - a. finite increments -> empirical zeta estimation；
 - b. mono/MRW projection and residual geometry；
 - c. calibrated diagnostics with warning。

建议优先重画

- Fig.5 finite-sample lambda2 recovery
 - 应成为正文核心主图；

- 比大表更能表达 finite-sample limitation。
- Fig.4 spectral geometry map
- Fig.7 failure attribution
- Fig.8 projection residual geometry

可以放附录或弱化

- Fig.9 real-data sanity check
 - 适合作为 sanity check;
 - 不适合作为强 real-world validation。

相关报告：

- `paper_writing_workspace/paper_assets/summaries/top_journal_figure_table_audit.md`
- `paper_writing_workspace/paper_assets/summaries/top_journal_writing_audit.md`
- `paper_writing_workspace/paper_assets/summaries/latex_float_and_layout_fix_report.md`

13. 常见误解和正确说法

误解 1： p_{MRW} 高就证明数据是 MRW

错误。

正确说法：

p_{MRW} is a calibrated diagnostic compatibility score.
It should be interpreted together with p_{curved} , p_{mono} , residuals, tail instability, and finite-sample uncertainty.

误解 2： λ_{2_proj} 就是真实 λ_{2_true}

错误。

正确说法：

λ_{2_proj} is a projection coordinate.
It does not prove the data-generating mechanism.

误解 3：模型失败了，所以论文价值不大

不准确。

项目最有价值的结论恰恰是：

`clean spectral geometry is identifiable,
but raw finite-sample curvature recovery is bottlenecked by empirical zeta estimation.`

这使论文从“刷指标模型”变成“有限样本多重分形诊断与可识别性分析”。

误解 4：继续加 head / loss / backbone 就能解决

目前证据不支持。

deterministic estimators 也恢复不了 λ^2 ，说明瓶颈更可能在：

- q-grid 太稀；
- scale range 太窄；
- T 太短；
- high-q moments 不稳定；
- structure-function estimator 不够强；
- MRW 曲率在有限样本下本身不可识别。

14. 下一步最合理的工作

如果目标是写论文，而不是继续研发模型，建议顺序：

1. 重画 Fig.1。
2. 重画 Fig.5，把 finite-sample identifiability 讲清楚。
3. 精修 Introduction 和 Conclusion，强调 diagnostic framework。
4. 把 legacy 阶段移到 appendix 或 supplement。
5. 检查所有 claim-evidence 对应关系。
6. 准备投稿版本的表格和 caption。
7. 如果还有时间，再补更强的经典 estimator baseline，如 wavelet leader / WTMM / MFDFA 完整版。

15. 最短读项目路线

如果你只想快速重新理解项目，建议按这个顺序读：

1. README.md
2. docs/project_implementation_guide_cn.md
3. docs/final_project_manifest.md
4. docs/spectral_representation_framework.md
5. docs/finite_sample_curvature_identifiability.md
6. paper_writing_workspace/ARTICLE_STRUCTURE_CN.md
7. paper_writing_workspace/paper_assets/summaries/top_journal_figure_table_audit.md

如果你要改代码，再读：

1. docs/core_code_index.md
2. src/mrw_inverse/models/mrw_projection.py
3. src/mrw_inverse/models/monofractal_projection.py
4. src/mrw_inverse/models/curvature_diagnostics.py
5. src/mrw_inverse/models/spectral_geometry_calibrator.py
6. src/mrw_inverse/analysis/curvature_identifiability.py

16. 最终定位

这个项目最稳的论文定位是：

一个物理/谱几何约束的有限样本多重分形诊断框架。

它显示：

1. analytic spectral geometry 可以被稳定学习；
2. raw empirical spectrum estimation 是主要瓶颈；
3. short-window λ^2 recovery 在当前 estimator/q-grid/scale range 下不可可靠保证；
4. 因此多重分形诊断应同时报告 scaling、curvature、mono/MRW residuals、instability warnings 和 finite-sample identifiability limits。

这条主线保守、清楚，也最不容易被审稿人攻击。